

Análisis exploratorio y caracterización de variables fisicoquímicas asociadas a la calidad del vino

Jose Camilo Loaiza Hoyos
Departamento de Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia
camilo.loaiza1@udea.edu.co

Sarai Restrepo Rodríguez
Departamento de Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia
sarai.restrepo@udea.edu.co

Resumen—Este trabajo analiza el conjunto de datos *Wine Quality* del UCI Machine Learning Repository [1], compuesto por 6497 muestras de vinos *Vinho Verde* portugueses (1599 tintos y 4898 blancos) con 11 variables fisicoquímicas continuas y una evaluación sensorial de calidad ordinal. El objetivo es caracterizar dichas variables e identificar cuáles presentan mayor asociación con la calidad sensorial, mediante un proceso analítico completo de ciencia de datos. Se aplicaron técnicas de análisis exploratorio univariado, bivariado y multivariado —incluyendo Análisis de Componentes Principales (PCA)—, métodos estadísticos y de aprendizaje automático para la detección de valores atípicos, y estrategias de preprocesamiento que comprenden eliminación de duplicados, transformación Yeo–Johnson y escalamiento. Los resultados muestran que *alcohol* es la variable con mayor correlación monótona con la calidad ($\rho_{\text{Spearman}} \approx 0,45$), seguida por *density* ($\rho \approx -0,32$) y *chlorides* ($\rho \approx -0,30$). El PCA evidencia que el primer componente separa los vinos tintos de los blancos, mientras que el gradiente de calidad en el espacio reducido es difuso. Se concluye que las variables fisicoquímicas caracterizan parcialmente la calidad, pero el desbalance ordinal de clases y la subjetividad de la variable objetivo representan retos para el modelado supervisado posterior.

Index Terms—calidad del vino, análisis exploratorio de datos, detección de valores atípicos, transformación Yeo–Johnson, análisis de componentes principales

I. INTRODUCCIÓN

La industria vitivinícola es uno de los sectores agroalimentarios de mayor relevancia económica a nivel mundial, y la calidad del vino constituye uno de sus principales criterios de valor comercial y sensorial [2]. Tradicionalmente, la evaluación de la calidad se realiza mediante paneles de catadores que asignan una puntuación sensorial basada en atributos organolépticos. Este procedimiento es costoso, requiere personal especializado y presenta variabilidad inherente al juicio humano [2]. Frente a esta limitación, el análisis de variables fisicoquímicas medibles en laboratorio ofrece una alternativa reproducible y cuantificable para estimar y comprender la calidad del vino desde una perspectiva basada en datos.

El presente trabajo analiza el conjunto de datos *Wine Quality* del repositorio UCI [1], que reúne mediciones de 6497 vinos *Vinho Verde* portugueses (1599 tintos y 4898 blancos). Para cada muestra se reportan once variables fisicoquímicas continuas y una variable ordinal *quality* en el rango [0, 10], calculada como la mediana de tres evaluaciones sensoriales independientes.

La **pregunta de investigación** que guía el análisis es: *¿qué variables fisicoquímicas presentan mayor asociación con la calidad sensorial del vino?*

El **objetivo general** es caracterizar las variables fisicoquímicas del conjunto y determinar cuáles muestran mayor asociación con la calidad sensorial, mediante un proceso analítico completo de ciencia de datos. Los **objetivos específicos** son: (i) describir la estructura y calidad inicial del conjunto; (ii) aplicar técnicas de análisis exploratorio univariado, bivariado y multivariado; (iii) identificar valores atípicos con métodos estadísticos y de aprendizaje automático; (iv) implementar estrategias de imputación, escalamiento y transformación; y (v) sintetizar los hallazgos para orientar etapas posteriores de modelado.

El artículo se organiza como sigue. La Sección II describe el conjunto de datos y las técnicas aplicadas. La Sección III presenta los resultados. La Sección IV resume hallazgos, limitaciones y líneas futuras.

II. METODOLOGÍA

II-A. Fuente y características del conjunto de datos

El conjunto *Wine Quality* [2] fue publicado en 2009 en el UCI Machine Learning Repository [1] y ha sido ampliamente empleado como banco de pruebas en estudios de ciencia de datos aplicados a la industria vitivinícola. Los datos provienen de la región portuguesa *Vinho Verde* y se dividen en dos subarchivos: 1599 muestras de vino tinto y 4898 de vino blanco, lo que genera un conjunto unificado de 6497 observaciones con 12 variables originales.

Las once primeras variables son mediciones fisicoquímicas continuas (acidez fija, acidez volátil, ácido cítrico, azúcar residual, cloruros, dióxido de azufre libre, dióxido de azufre total, densidad, pH, sulfatos y alcohol). La duodécima variable, *quality*, es de naturaleza ordinal entera y representa la mediana de tres juicios sensoriales independientes. En el proceso de integración se añadió una variable categórica nominal *tipo* (tinto/blanco) para habilitar comparaciones entre subconjuntos.

II-B. Análisis exploratorio de datos

El análisis exploratorio se estructuró en tres niveles siguiendo las orientaciones teóricas del curso:

Análisis univariado. Para cada variable continua se calcularon media, mediana, desviación estándar, coeficiente de variación, asimetría y curtosis mediante las librerías pandas [3] y SciPy. Las distribuciones se visualizaron con histogramas, diagramas de caja y gráficas de percentiles, empleando matplotlib [4] y seaborn [5].

Análisis bivariado. Se calcularon los coeficientes de correlación de Pearson (r) y Spearman (ρ) entre todas las variables continuas y `quality`. Dado el carácter ordinal de la variable objetivo, ρ resulta más apropiado. La asociación entre las variables categóricas `tipo` y `quality` se evaluó con la prueba χ^2 de independencia y el tamaño del efecto con la V de Cramér.

Análisis multivariado. Se aplicó Análisis de Componentes Principales (PCA) con scikit-learn [6] sobre los datos estandarizados para estudiar la estructura de varianza del conjunto y la separabilidad de las variables de agrupación (`tipo`, `quality`).

II-C. Detección de valores atípicos

Se emplearon cuatro métodos agrupados en dos familias:

Métodos estadísticos univariados. (a) *Regla del rango intercuartílico (IQR)*: una observación es atípica si su valor cae fuera del intervalo $[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR]$. (b) *Puntaje Z*: umbral $|z| > 3,0$.

Métodos de aprendizaje automático multivariados. (a) *Isolation Forest* [7]: construye árboles aleatorios que aíslan observaciones; los atípicos requieren menos divisiones. (b) *Local Outlier Factor (LOF)* [8]: mide la densidad local relativa a los vecinos de cada observación. Ambos se calibraron con `contamination=0.05` (5 %) sobre los datos estandarizados. Se usó `SEED=42` para reproducibilidad.

II-D. Preprocesamiento

El preprocesamiento siguió el siguiente flujo:

1. **Eliminación de duplicados exactos.** Se verificó la ausencia de valores faltantes y se eliminaron las filas duplicadas.
2. **Imputación KNN.** Con fines demostrativos, se aplicó `KNNImputer` (scikit-learn, $k=5$) sobre un escenario MCAR simulado al 5 %.
3. **Transformación Yeo-Johnson** [9]: aplicada a las variables con $|\text{skewness}| > 1$ para reducir la asimetría y comprimir colas extremas.
4. **Escalamiento.** `StandardScaler`: estandarización $z = (x - \mu) / \sigma$, elegida por ser coherente con el conjunto post-transformación aproximadamente simétrico.

III. RESULTADOS Y ANÁLISIS

III-A. Caracterización general del conjunto

El conjunto unificado contiene 6497 observaciones: 1599 tintos (24,6 %) y 4898 blancos (75,4 %). La Figura 1 muestra la distribución de `quality`: el 92 % de los vinos se concentra en los niveles 5, 6 y 7, mientras que las clases extremas (3, 4, 8, 9) son muy escasas, un caso típico de desbalance ordinal. Las




Figura 1. Distribución de `quality` por tipo de vino. Las clases 5–7 concentran más del 90 % de las observaciones.




Figura 2. Distribuciones de las once variables fisicoquímicas. Variables con cola derecha larga son candidatas a transformación.

variables fisicoquímicas operan en escalas muy distintas — densidad ≈ 1 frente a total sulfur dioxide > 200 —, lo que justifica el escalamiento previo a cualquier técnica sensible a la magnitud.

III-B. Análisis univariado: distribuciones y estadísticas descriptivas

La Figura 2 presenta los histogramas de las once variables fisicoquímicas. Seis variables exhiben asimetría positiva marcada ($|\text{skew}| > 1$): `chlorides` (5,40), `sulphates` (1,80), `residual sugar` (1,44), `fixed acidity` (1,72), `volatile acidity` (1,50) y `free sulfur dioxide` (1,22), con colas derechas extensas características de distribuciones lognormales. En el extremo opuesto, `total sulfur dioxide` (≈ 0) y `pH` (0,39) son las más simétricas, mientras que `density` (0,50) presenta solo una asimetría leve. Estas diferencias de forma motivaron el uso de Yeo-Johnson en la etapa de preprocesamiento.




Figura 3. Matrices de correlación de Pearson (izquierda) y Spearman (derecha) sobre el conjunto unificado.




Figura 4. Diagramas de caja por tipo de vino para cada variable fisicoquímica. Se aprecia la separación estructural más marcada en `total_sulfur_dioxide` y `volatile_acidity`.

III-C. Relaciones entre variables y calidad

La Figura 3 muestra las matrices de correlación de Pearson y Spearman. El ranking por $|\rho_{\text{Spearman}}|$ con `quality` ubica a `alcohol` ($\rho \approx 0,45$) como la variable de mayor asociación monótona, seguida de `density` ($\rho \approx -0,32$), `chlorides` ($\rho \approx -0,30$) y `volatile acidity` ($\rho \approx -0,26$). Las diferencias entre las matrices de Pearson y Spearman son moderadas, lo que sugiere relaciones principalmente monótonas con algunas no linealidades locales.

La comparación por tipo (Fig. 4) revela diferencias estructurales marcadas en `total sulfur dioxide`, `volatile acidity`, `free sulfur dioxide` y `chlorides`: los blancos presentan mayor contenido de SO_2 total, mientras que los tintos exhiben mayor acidez volátil y mayor contenido de cloruros.

La prueba χ^2 sobre `tipo` vs. `quality` discretizada confirmó asociación estadísticamente significativa. Sin embargo,




Figura 5. Diagrama de codo del PCA. PC1 explica el 27,5 % de la varianza; cinco componentes acumulan el 80 %.




Figura 6. Biplot PCA (PC1-PC2). Los vectores de carga muestran las variables que mejor explican cada componente. PC1 discrimina tinto de blanco; PC2 captura el contraste densidad-alcohol.

la V de Cramér ($\approx 0,09$) indica un tamaño del efecto pequeño: el tipo de vino influye en la calidad percibida pero no la determina.

III-D. Análisis multivariado: PCA

La Figura 5 presenta el diagrama de codo del PCA. PC1 explica el 27,5 % de la varianza y PC2 el 22,7 %; se requieren cinco componentes para acumular el 80 %. El biplot (Fig. 6) muestra que `total sulfur dioxide`, `residual sugar` y `free sulfur dioxide` tienen cargas negativas altas en PC1, mientras que `volatile acidity`, `chlorides` y `sulphates` apuntan en la dirección opuesta, lo que produce una separación nítida entre vinos tintos y blancos sobre el eje de PC1.

La proyección de las observaciones sobre el plano PC1-PC2 coloreada por `quality` (Fig. 7) presenta un gradiente




Figura 7. Proyección PCA coloreada por *quality*. El gradiente de calidad en el espacio PC1-PC2 es difuso, lo que indica que los componentes principales no discriminan directamente la calidad.




Figura 8. Concordancia entre Isolation Forest y LOF. La superposición parcial refleja las distintas nociones de anomalía de cada método.

difuso: no existe una región del espacio reducido donde los vinos de alta o baja calidad se concentren nítidamente. Este resultado anticipa que la predicción de la calidad requerirá modelos capaces de capturar interacciones y no linealidades.

III-E. Detección de valores atípicos

Los métodos estadísticos univariados detectaron la mayor cantidad de atípicos en las variables con distribuciones sesgadas: *residual sugar*, *chlorides* y *sulphates*. La regla IQR resultó más sensible que el puntaje Z en este contexto, ya que la presencia de valores extremos infla la desviación estándar muestral, ampliando el umbral $\pm 3s$ y reduciendo la sensibilidad del criterio Z.

Los métodos de aprendizaje automático (Isolation Forest y LOF), calibrados al 5 %, capturaron geometrías distintas de anomalía: Isolation Forest detecta atípicos globales bien separados del conjunto, mientras que LOF identifica puntos de baja densidad local (Fig. 8). La coincidencia exacta entre ambos métodos fue modesta, lo que refleja que cada algoritmo opera sobre una noción diferente de anomalía. Las observaciones marcadas por los cuatro métodos simultáneamente constituyeron menos del 2 % del conjunto y representan los candidatos más sólidos a revisión manual.

Tabla I
FLUJO DE PREPROCESAMIENTO DEL CONJUNTO *Wine Quality*

Etapas	Filas	Acción principal
Conjunto crudo unificado	6 497	—
Eliminación de duplicados	5 320	—1 177 filas (18,1 %)
Transformación Yeo-Johnson	5 320	Variables con $ \text{skew} > 1$
Escalamiento StandardScaler	5 320	Todas las fisicoquímicas
Conjunto exportado	5 320	<code>winequality_procesado.csv</code>




Figura 9. Validación de la imputación KNN sobre el escenario MCAR simulado al 5 %. Los valores imputados (naranja) reproducen la distribución original (azul) con error reducido.

Dado que las distribuciones son intrínsecamente asimétricas y los valores extremos son químicamente plausibles, se optó por **no eliminar** los atípicos univariados de forma indiscriminada, sino por tratarlos mediante transformación Yeo-Johnson en la etapa de preprocesamiento.

III-F. Preprocesamiento aplicado

La Tabla I resume el flujo de preprocesamiento.

Se eliminaron 1 177 filas duplicadas exactas (18,1 % del conjunto crudo), lo que reduce el conjunto a 5 320 observaciones. Con fines demostrativos, se simuló un escenario de valores faltantes completamente aleatorios (MCAR) al 5 % y se aplicó `KNNImputer` ($k = 5$) para su recuperación; la Figura 9 muestra que los valores imputados reproducen la distribución original con error bajo, validando la estrategia.

La transformación Yeo-Johnson [9] se aplicó a las seis variables con $|\text{skew}| > 1$ (*chlorides*, *sulphates*, *residual sugar*, *fixed acidity*, *volatile acidity* y *free sulfur dioxide*), reduciendo drásticamente su asimetría sin descartar observaciones, como se aprecia en la Figura 10. Tras la transformación, el `StandardScaler` fue la opción más apropiada por producir distribuciones centradas y con varianza unitaria, coherentes con análisis posteriores basados en distancias o covarianzas (Fig. 11).

IV. CONCLUSIONES

Este trabajo realizó un análisis exploratorio completo del conjunto *Wine Quality*, cubriendo cuatro bloques metodológicos: análisis exploratorio (univariado, bivariado y multiva-

Efecto de la transformación Yeo-Johnson sobre la asimetría




Figura 10. Efecto de la transformación Yeo-Johnson sobre las variables con mayor asimetría. Se observa una reducción considerable del sesgo y la elongación de las colas.




Figura 11. Comparación de StandardScaler, MinMaxScaler y RobustScaler aplicados al conjunto post-transformación. StandardScaler produce la distribución más equilibrada tras Yeo-Johnson.

riado), detección de atípicos, preprocesamiento y síntesis de hallazgos.

Los resultados principales son:

1. `alcohol` es la variable con mayor asociación monótona con la calidad sensorial ($\rho_{\text{spearman}} \approx 0,45$), seguida de `density` ($\rho \approx -0,32$) y `chlorides` ($\rho \approx -0,30$), patrón consistente con la literatura original del dataset [2].
2. El PCA revela que la principal fuente de varianza (PC1,

27,5 %) es el contraste químico entre vinos tintos y blancos, no la calidad. El gradiente de calidad en el espacio reducido es difuso, lo que anticipa la necesidad de modelos no lineales para predecirla (árboles, ensambles).

3. La asociación entre tipo de vino y calidad, aunque estadísticamente significativa, es débil (V de Cramér $\approx 0,09$): el tipo influye pero no determina la calidad percibida.
4. Los métodos univariados (IQR, Z-score) y multivariados (Isolation Forest [7], LOF [8]) capturan geometrías distintas de anomalía. La decisión de conservar los atípicos univariados, compensando su efecto con Yeo-Johnson, es metodológicamente sólida dado el carácter legítimo de los valores extremos en datos vitivinícolas.
5. El flujo *deduplicar* $\rightarrow$ *imputar* $\rightarrow$ *transformar* $\rightarrow$ *escalar* produce un conjunto de 5320 observaciones consistente, centrado y con varianza unitaria, listo para modelado supervisado.

Limitaciones. El análisis es exclusivamente exploratorio: no se construyó ni validó ningún modelo predictivo. Los vinos provienen de una única región (*Vinho Verde*, Portugal) y de una única ventana temporal, por lo que los hallazgos pueden no generalizar a otros estilos. El fuerte desbalance ordinal de `quality` (90 % en clases 5–7) condicionará cualquier modelado posterior.

Trabajo futuro. Las líneas naturales de continuación incluyen: (i) modelado supervisado de `quality` con árboles de decisión, ensambles y validación cruzada estratificada; (ii) tratamiento explícito del desbalance ordinal (SMOTE, ponderación de clases); (iii) análisis estratificado por tipo de vino; e (iv) ingeniería de variables con ratios fisicoquímicos relevantes.

CONSIDERACIONES ÉTICAS Y DISPONIBILIDAD DE DATOS

El conjunto *Wine Quality* fue publicado bajo licencia abierta por Cortez et al. [2] en el UCI Machine Learning Repository [1]. Los datos corresponden exclusivamente a mediciones químicas y calificaciones sensoriales agregadas; no contienen información personal ni de identificación. El código fuente, el notebook y el conjunto procesado están disponibles en el repositorio público del proyecto: <https://github.com/caamilo03/wine-quality>.

REFERENCIAS

- [1] UCI Machine Learning Repository, “Wine quality data set,” <https://archive.ics.uci.edu/dataset/186/wine+quality>, 2009.
- [2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, “Modeling wine preferences by data mining from physicochemical properties,” *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, 2009.
- [3] W. McKinney, “Data structures for statistical computing in Python,” in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 56–61.
- [4] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.
- [5] M. L. Waskom, “seaborn: statistical data visualization,” *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021.

- [6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [7] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413–422.
- [8] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: Identifying density-based local outliers," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 2000, pp. 93–104.
- [9] I.-K. Yeo and R. A. Johnson, "A new family of power transformations to improve normality or symmetry," *Biometrika*, vol. 87, no. 4, pp. 954–959, 2000.